

# OPORTUNIDADES Y RETOS DEL MACHINE LEARNING PARA LOS SERVICIOS FINANCIEROS

Andrade Farias David Agustin

17 de octubre de 2023

## Resumen

Los métodos basados en la inteligencia artificial están transformando multitud de sectores al permitir automatizar tareas rutinarias e importantes mejoras en el análisis de la información. El sector financiero no es ajeno a esta tendencia y está tratando de aprovechar las oportunidades de estas técnicas al tiempo que debe ser consciente y actuar ante los riesgos y limitaciones que implican

## 1. Introducción

La inteligencia artificial y los modelos de machine learning no son algo nuevo, sus propuestas datan de más de medio siglo y, de hecho, el término «inteligencia artificial» se acuñó por primera vez durante la Conferencia de Dartmouth en 1956, si bien, en gran parte estas propuestas permanecían en un ámbito más bien teórico y limitado por la escasa capacidad de computación existente. Sin embargo, en los últimos años, en un entorno de aumento en la capacidad de almacenamiento y procesamiento de la información, sus aplicaciones han dejado de estar vinculadas a casos anecdóticos —como los juegos de ajedrez o de preguntas para empezar a realizar tareas que los humanos desarrollamos de modo habitual, como el reconocimiento de voz y de imágenes<sup>1</sup> o la identificación de patrones

## 2. El uso de la inteligencia artificial en el sector financiero: un nuevo paradigma

En finanzas, el principal uso de las técnicas de inteligencia artificial se enfoca básicamente en predecir una variable (generalmente binaria, como, por ejemplo, sería el caso de estimar un posible impago o la satisfacción de un cliente bancario) manejando la información disponible de un modo muy flexible y sin suponer ninguna relación subyacente entre las variables, es decir, desde un

punto de partida completamente agnóstico sobre el proceso de generación de datos (Agrawal et al., 2018). Esta flexibilidad, unida a la mejora en la precisión que puede alcanzarse, hace que las aplicaciones sean mayores que con las técnicas econométricas tradicionales, en las que para predecir necesitamos una relación teórica subyacente entre las variables. Así, podemos encontrarnos que el uso de estos algoritmos abarca no solo aquellos entornos donde venía siendo habitual emplear análisis de regresiones lineales, sino que también incluye el propio tratamiento de datos —agrupando las observaciones en distintos clusters o reduciendo la dimensión de nuestros datos—, la toma de decisiones o incluso la inferencia causal, renunciando, en este caso (al menos en parte), a la flexibilidad sobre el proceso generador de los datos que se ha comentado anteriormente.

## **2.1. La inteligencia artificial frente a la tradición estadística en el sector financiero**

Evidentemente, la mayoría de estas aplicaciones no han nacido con el ML pero, frente a los modelos tradicionales econométricos que podrían usarse, por ejemplo, para la toma de decisiones de si dar un crédito o no o para realizar la predicción de una variable macroeconómica, las técnicas de ML suponen un importante complemento que, en muchos casos, pueden mejorar el uso que se hacía con esas herramientas estadísticas (Mullainathan y Spiess, 2017; Athey, 2018; Athey e Imbens, 2019). De hecho, en ciertos campos, como el reconocimiento facial, o los chatbots, no existen alternativas viables al ML dentro de la econometría tradicional. Esto es así porque la flexibilidad en la modelización y el poder predictivo que aporta el ML es muy superior a lo que pueden proporcionar los modelos necesariamente más simples a los que se ve constreñida la econometría tradicional. El ML está especialmente preparado para tratar fenómenos o problemas complejos en los que se pueden producir situaciones tales como datos no estándares, alta dimensionalidad de nuestra base de datos, múltiples interacciones (incluso no lineales) entre estas variables, o correlaciones en las colas de las distribuciones. La econometría tradicional ha desarrollado soluciones puntuales para muchos de estos problemas: modelos factoriales para la alta dimensionalidad, modelos de diferencias en diferencias o de regresiones en discontinuidad que están diseñados específicamente para interacciones, o modelos de regresión cuantílica para las colas de las distribuciones, entre otras muchas. Sin embargo, estas soluciones son particulares para situaciones concretas, y difícilmente combinables si se dan dos o tres de estos problemas a la vez. Sin embargo, la versatilidad del ML permite explorar cualquier combinación de estos fenómenos a la que nos podamos enfrentar, lo que lleva a una identificación de las especificaciones óptimas de forma mucho más agnóstica, sin los supuestos *a priori* que pueden sesgar la ciencia económica tradicional (Breiman, 2001; Maurya et al., 2020). Por decirlo de otra forma, con el ML se prima la aproximación lo más fidedigna posible a una realidad compleja y la mayor capacidad de predicción posible, frente a la aproximación común que parte de un modelo (por definición y etimológicamente, una simplificación de la realidad) predeterminado.

## **2.2. Retos para las autoridades en el uso de las técnicas de machine learning/artificial intelligence**

A lo largo del apartado anterior, se han mencionado algunas de las cuestiones a las que el analista debe hacer frente a la hora de utilizar las técnicas de ML. Adicionalmente, estas técnicas plantean una serie de cuestiones a las autoridades financieras relacionadas tanto con la forma en la que pueden mitigar riesgos conocidos como con la aparición de nuevas cuestiones que se plantean en relación con valores fundamentales de la sociedad que deben ser preservados. En este sentido, el analista debe ser consciente de la normativa que afecta a estos procedimientos, mucha de la cual, como se verá en este apartado, está en proceso de elaboración. El uso de la inteligencia artificial, desde un punto de vista general, y no centrado exclusivamente en el sector financiero, plantea un importante dilema para las autoridades que, por un lado, tratan de fomentar su uso y trasladar a los usuarios las ganancias en eficiencia derivadas de la innovación tecnológica y, por otro lado, deben preservar el cumplimiento de valores fundamentales como la no manipulación del usuario, la no discriminación entre individuos por causas no deseables o la protección de la privacidad recogidas en una normativa desarrollada con carácter previo al uso de estos algoritmos. En el caso de Europa, este dilema se está abordando, además de con iniciativas generales que afectan al uso de la inteligencia como la estrategia de computación en la nube o la de datos, con dos iniciativas de carácter más específico: un plan coordinado para potenciar el uso de la inteligencia artificial, y una propuesta de Reglamento para regular y mitigar los riesgos derivados del uso de la inteligencia artificial (European Commission [EC], 2021)

**2.3. Oportunidades: Mejora en la toma de decisiones** Con el ML, las instituciones financieras pueden analizar grandes conjuntos de datos para identificar tendencias, patrones y anomalías, lo que permite tomar decisiones más informadas.

**2.4. Personalización del servicio al cliente:** Los algoritmos de ML pueden analizar el comportamiento del cliente y ofrecer productos o servicios personalizados, mejorando la experiencia del cliente y aumentando la retención.

**2.5. Prevención del fraude:**

Los sistemas de IA pueden identificar rápidamente actividades sospechosas, reduciendo significativamente las pérdidas por fraude.

### 3. Automatización:

Tareas rutinarias, como la verificación de documentos o el procesamiento de transacciones, se pueden automatizar, reduciendo errores humanos y aumentando la eficiencia.




Figura 1: La calidad de los datos es fundamental para el rendimiento del ML. La información incorrecta o sesgada puede llevar a decisiones erróneas.

### 4. Conclusiones

Las nuevas posibilidades tecnológicas, unidas a la capacidad para recopilar y procesar fuentes de información, hacen que las técnicas de inteligencia artificial y aprendizaje automático (machine learning) puedan aplicarse en múltiples procesos tanto básicos como analíticos en prácticamente todos los sectores de la actividad económica. El sector financiero no es ajeno a este fenómeno, sin duda alguna disruptivo y que puede ayudarle a obtener mejoras significativas de eficiencia y precisión en procesos como la concesión de crédito y ahorros importantes en tareas repetitivas. No obstante, aunque estas técnicas mejoran en términos predictivos las capacidades de los modelos econométricos tradicionales, también tienen importantes desafíos como la dificultad para explicar los resultados, la estabilidad de los mismos o la posibilidad de perpetuar sesgos discriminatorios. Estos desafíos deben ser tenidos en cuenta por parte de los profesionales y empresas que usen estos modelos, si bien, algunos de ellos también afectan a otros modelos tradicionales y deben formar parte de una estrategia integral de las empresas a la hora de gestionar y explotar la información. Por otro lado, la importancia de muchos de estos desafíos depende, en gran medida, del contexto en el que se estén empleando los procesos de AI ML, en este sentido, las autoridades públicas están planteando marcos normativos que realicen

una serie de requerimientos en función del nivel de riesgo que implica la automatización y el análisis avanzado de los datos para los derechos fundamentales de los ciudadanos

## 5. Referencias bibliográficas

Agrawal, A., Gans, J., GoldFarb, A. (2018). Prediction Machines: The Simple Economist of Artificial Intelligence. Harvard Business Review Press. Alonso, A., Carbó, J. M. (2020). Machine learning in credit risk: measuring the dilemma between prediction and supervisory cost (Documento de trabajo del Banco de España n.º 2032). Alonso, A., Carbó, J. M. (2022). Accuracy and stability of explanations of machine learning models for credit default prediction. Journal of Financial Innovation. Forthcoming. Athey, S. (2018). The impact of machine learning on economics. The economics of artificial intelligence: An agenda, 507-547. Athey, S., Imbens, G. W. (2019). Machine learning methods that economists should know about. Annual Review of Economics, 11, 685-725. BaFin, Bundesanstalt für Finanzdienstleistungsaufsicht. (2021). Big data and AI: Principles for the use of algorithms in decision-making processes. Bartlett, R., Morse, A., Stanton, R., Wallace, N. (2022). Consumer-lending discrimination in the FinTech era. Journal of Financial Economics, 143(1), 30-56. Blanchard, O. (2017). Do DSGE models have a future? In R. S. Gürkaynak, C. Tille (Eds.), DSGE Models in the Conduct of Policy: Use as intended (pp. 93-100). CEPR Press. BoE, Bank of England. (2019). Machine learning in UK financial services. Bono, T., Croxson, K., Giles, A. (2021). Algorithmic fairness in credit scoring. Oxford Review of Economic Policy, 37(3), 585-617. Breiman, L. (2001). Statistical Modeling: The Two Cultures. Statistical Science, 16(3), 199-215. DBE/BaFin, Deutsch BundesBank Eurosystem/Bundesanstalt für Finanzdienstleistungsaufsicht. (2021). Machine learning in risk models – Characteristics and supervisory priorities. De Andrés, P., Gimeno, R., Mateos de Cabo, R. (2021). The gender gap in bank credit access. Journal of Corporate Finance, 71, 101782. Dobbie, W., Liberman, A., Paravisini, D., Pathania, V. (2021). Measuring bias in consumer lending. The Review of Economic Studies, 88(6), 2799-2832. Ricardo Gimeno y José Manuel Marqués 118 ICE EL FUTURO DEL DINERO Y LA TRANSFORMACIÓN DIGITAL DEL SECTOR FINANCIERO Mayo-Junio 2022. N.º 926 Dupont, L., Fliche, O., Yang, S. (2020). Governance of Artificial Intelligence in Finance. Banque De France. EBA, European Banking Authority. (2020). Report on Big Data and Advanced Analytics. EBA, European Banking Authority. (2021). Discussion Paper on Machine Learning for IRB Models. EC, European Commission. (2021). Fostering a European approach to Artificial Intelligence. COM(2021) 205 final. Fernández Bedoya, A. (2019). Inteligencia Artificial en los servicios financieros. Boletín Económico del Banco de España n.º 2/2019. Artículos analíticos. FSB, Financial Stability Board. (2017). Artificial intelligence and machine learning in financial services. Market developments and financial stability implications. Fuster, A., Goldsmith-Pinkham, P., Ramadorai, T., Walther, A. (2022). Predictably unequal? The effects of machi-

ne learning on credit markets. *The Journal of Finance*, 77(1), 5-47. Goldwasser, S., Kim, M. P., Vaikuntanathan, V., Zamir, O. (2022). Planting Undetectable Backdoors in Machine Learning Models. arXiv preprint arXiv:2204.06974. Goodell, J. W., Kumar, S., Lim, W. M., Pattnaik, D. (2021). Artificial intelligence and machine learning in finance: Identifying foundations, themes, and research clusters from bibliometric analysis. *Journal of Behavioral and Experimental Finance*, 32, 100577. Hoepner, A. G. F., McMillan, D., Vivian, A., Simen, C. W. (2021). Significance, relevance and explainability in the machine learning age: an econometrics and financial data science perspective. *The European Journal of Finance*, 27(1-2), 1-7. IIF, Institute of International Finance. (2019). *Machine Learning in Credit Risk* (2nd edition). IIF, Institute of International Finance. (2020). *Machine Learning governance*. Königstorfer, F., Thalmann, S. (2020). Applications of Artificial Intelligence in commercial banks – A research agenda for behavioral finance. *Journal of Behavioral and Experimental Finance*, 27, 100352. Lundberg, S. M., Lee, S. I. (2017). A unified approach to interpreting model predictions. In S. Thrun, L. K. Saul, B. Schölkopf (Eds.), *Advances in neural information processing systems* (pp. 4765-4774). Maurya, N., Kumar, N., Maurya, V. K. (2020). A Review on Machine Learning (Feature Selection, Classification and Clustering) Approaches of Big Data Mining in Different Area of Research. *Journal of Critical Reviews*, 7(19), 2610-2626. Molnar, C. (2020). *Interpretable machine learning. A guide for making black box models interpretable*. Lulu.com. Mullainathan, S., Spiess, J. (2017). Machine learning: an applied econometric approach. *Journal of Economic Perspectives*, 31(2), 87-106. OECD, Organisation for Economic Co-operation and Development. (2021). *Artificial Intelligence, Machine Learning and Big Data in Finance. Opportunities, Challenges and Implications for Policy Makers*. Phelps, E. S. (1972). The Statistical Theory of Racism and Sexism. *American Economic Review*, 62(4), 659-661. Ribeiro, M. T., Singh, S., Guestrin, C. (2016, August). "Why should I trust you?". Explaining the predictions of any classifier. In *Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining* (pp. 1135-1144). Romer, P. (2016). *The Trouble with Macroeconomics*. Commons Memorial Lecture of the Omicron Delta Epsilon Society